



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

DEPARTAMENTO
DE INGENIERÍA
COMERCIAL

Predicción de Churn ABC Bank

De datos a decisiones de retención

Objetivo de negocio

Anticipar qué clientes podrían abandonar el banco y priorizar campañas de retención con base en riesgo, valor y costo económico.



Ruta de exposición

Nicolás Collao

Problema, datos y EDA

Slides 1-4 |

Ignacio Ponce

Modelos, métricas y umbral

Slides 5-8 |

Michelle Retamales

Segmentos, acciones y cierre

Slides 9-12 |

Mensaje central: el modelo no reemplaza la decisión comercial; ayuda a priorizar clientes y diseñar intervenciones más eficientes.



1. Problema de negocio

¿Por qué predecir churn es valioso para ABC Bank?

20,37%

clientes abandonan el banco

10.000

clientes analizados

?

umbral económico recomendado


Traducción a negocio

El desafío no es solo predecir quién se va, sino decidir a quién contactar primero para reducir pérdidas sin malgastar presupuesto de retención.



2. Hallazgos clave del EDA

La exploración guió el preprocesamiento y las hipótesis del modelo



■ Permanece ■ Churn

Edad

El churn aumenta con fuerza en grupos de 41-60 años.

Actividad

Clientes inactivos duplican aproximadamente el abandono observado.

Productos

Dos productos es el perfil más estable; uno, tres o cuatro elevan el riesgo.

País

Alemania concentra el mayor riesgo relativo.

Calidad de datos: sin valores faltantes y sin duplicados exactos relevantes. Se mantuvieron atípicos porque pueden representar clientes reales.



3. Preparación y estrategia de modelado

Cuatro modelos, misma base de comparación y separación estratificada

1

Variables categóricas

One-Hot Encoding para país y género.

2

Escalamiento

RobustScaler para reducir efecto de valores extremos.

3

Balance de clases

Pesos de clase y separación estratificada.

4

Modelos evaluados

Regresión logística, árbol, random forest y gradient boosting.

Criterio de evaluación: ROC-AUC como métrica principal, complementada con precision, recall, F1-score, matriz de confusión y costo económico.



4. Comparación de modelos

Gradient Boosting obtuvo la mayor capacidad de discriminación

Modelo	ROC-AUC	PR-AUC	Recall	F1-score	Lectura
Gradient Boosting	0,871	0,718	0,757	0,606	Mejor desempeño global
Random Forest	0,865	0,697	0,705	0,629	Muy competitivo
Árbol de Decisión	0,843	0,645	0,769	0,571	Simple, menor estabilidad
Regresión Logística	0,777	0,468	0,705	0,502	Baseline interpretable





5. Modelo seleccionado: Gradient Boosting

Seleccionado por desempeño y capacidad para capturar relaciones no lineales

0,871

ROC-AUC

0,718

PR-AUC

Buen balance entre detectar clientes que se van y ordenar bien los niveles de riesgo.

Aprende patrones secuencialmente: cada árbol corrige errores del anterior.
Captura interacciones entre edad, actividad, país, saldo y productos.
Es adecuado para datos tabulares con relaciones no lineales.
No se elige solo por accuracy; se prioriza valor de negocio.

Limitación: las probabilidades no son perfectas. Se recomienda usarlo como ranking de prioridad y calibrarlo si pasa a producción.



6. Umbral óptimo de negocio

El umbral 0,31 prioriza capturar clientes en riesgo

Comparación de criterios

Criterio	Umbral	Efecto
Tradicional	0,50	Más precisión, pero pierde más churners
F1-score	0,63	Mejor balance estadístico
Costo económico	0,31	Menor costo estimado y mayor recall

89,7%

recall con umbral 0,31

990

clientes contactados de 2.000

Con los datos de prueba, había **407 clientes que realmente hicieron churn**. Con umbral 0,31, se identificaron aproximadamente:

$$Recall = \frac{365}{407} = 0,897$$

Con esa regla, logramos detectar el 89,7% de los clientes que realmente abandonan.

La decisión es económica: perder un cliente no detectado cuesta más que contactarlo preventivamente.



7. Segmentación por riesgo

El modelo permite separar clientes en acciones diferenciadas

Nivel	Clientes	Prob. media	Churn observado	Churners reales	Acción
Alto	990	59,99%	36,87%	365	Contactar primero
Medio	317	26,03%	7,26%	23	Automatizar y monitorear
Bajo	693	13,04%	2,74%	19	No contactar masivamente

Alto riesgo

Intervención personalizada

Riesgo medio

Campañas automáticas

Bajo riesgo


Monitoreo de bajo costo




8. ¿Dónde está el riesgo?

Segmentos con mayor churn observado y mayor concentración de alto riesgo

Churn observado por grupo etario



Churn por productos



Otros segmentos críticos

Alemania: 29,96% churn observado.
Inactivos: 27,48% churn observado.
Saldo positivo: 23,55% churn observado.
Saldo medio-bajo: 27,36% churn observado.

Insight principal: el mayor riesgo combina edad media/madura, inactividad, saldo positivo, un producto o sobre-vinculación, y presencia en Alemania.



9. Acciones recomendadas

Convertir probabilidades en campañas de retención accionables

Acción	Segmento objetivo	Qué hacer
Reactivación	Clientes inactivos	Incentivos por uso de app, cuenta y tarjeta.
Oferta inteligente	Clientes con 1 producto	Proponer segundo producto útil, no venta forzada.
Diagnóstico local	Alemania	Revisar servicio, costos, beneficios y competencia.
Protección de valor	Saldo positivo	Contacto preventivo y beneficios personalizados.
Revisión de cartera	3-4 productos	Detectar sobreventa, costos o baja satisfacción.

La campaña no debe ser igual para todos: riesgo alto + valor alto requiere intervención personalizada; riesgo medio puede gestionarse con automatización.



10. Meta próximo trimestre: reducir churn en 10%

Objetivo alcanzable si se interviene el grupo correcto

407

churners reales en prueba

≈41

clientes a retener para bajar 10%

4,1%

efectividad necesaria sobre alto riesgo

Plan operativo

1) Scoring mensual 2) Contacto a alto riesgo 3) Oferta diferenciada 4) Medición de churn evitado, respuesta y costo por cliente retenido.



11. Cierre ejecutivo

El valor del proyecto está en convertir datos en decisiones de retención

Conclusión

Gradient Boosting permite priorizar clientes con mayor riesgo de fuga y guiar campañas focalizadas. El modelo no debe usarse como verdad causal, sino como apoyo para decidir dónde invertir primero.

Próximo paso: piloto de 90 días con clientes de alto riesgo y seguimiento de churn evitado.

Recomendación final

**Implementar scoring
periódico, campañas por
segmento y medición
continua del retorno de
retención.**